

LAPORAN KOMPREHENSIF

Data Science

FaceHealth ID — Analisis Jerawat & Rekomendasi Skincare

Kode Capstone	CC26-PSU048
Learning Path	Data Science
Repository	alfnsn/FaceHealth-ID

1. Problem Discovery

1.1 Latar Belakang

Masalah jerawat (acne vulgaris) adalah masalah kulit yang sangat umum ditemui, mulai dari remaja hingga orang dewasa. Di Indonesia, banyaknya produk skincare yang beredar justru sering bikin bingung — orang membeli produk tanpa tahu apakah cocok dengan jenis jerawat atau tipe kulitnya. (Reynolds et al., 2024)

Pengguna sering memilih produk secara acak tanpa mempertimbangkan tipe kulit, sensitivitas, maupun jenis jerawat spesifiknya. Ketidaktepatan ini tidak hanya membuat perawatan tidak efektif, tapi berisiko memperparah kondisi kulit — terutama bagi pemilik kulit sensitif. (Sitohang et al., 2024)

1.2 Business Questions

Tiga pertanyaan bisnis yang menjadi panduan analisis:

	Business Question
BQ1	Bagaimana distribusi jenis jerawat (Comedonal, Inflammatory, Cyst) berdasarkan rentang usia dan sensitivitas kulit pengguna?
BQ2	Bahan aktif apa yang memiliki efektivitas tertinggi untuk masing-masing kondisi jerawat?
BQ3	Bagaimana distribusi jenis jerawat berdasarkan tipe kulit pengguna?

1.3 Solusi yang Diusulkan

Proyek ini membangun sistem berbasis Python yang bisa memberikan rekomendasi bahan aktif skincare sesuai profil kulit pengguna, meliputi tipe jerawat, tipe kulit, usia, dan sensitivitas. Hasilnya disajikan lewat dashboard Streamlit yang bisa dipakai sebagai bahan pertimbangan sebelum konsultasi ke dokter kulit.

2. Data Understanding

2.1 Sumber Data

Dataset yang digunakan adalah Skincare Treatment Dataset — dataset terstruktur yang berisi profil kulit pengguna beserta rekomendasi formulasi bahan aktif untuk perawatan jerawat. Dataset dimuat dari file CSV lokal: Skincare Treatment Dataset.csv.

2.2 Data Dictionary

Dataset ini punya 1.120 baris dan 9 kolom, mencakup informasi demografi, profil kulit, sampai rekomendasi formulasinya.

No	Kolom	Tipe	Deskripsi	Nilai Unik
----	-------	------	-----------	------------

1	Age_Group	string	Kelompok usia pengguna (14-18, 19-24, 25-36, 37-45, 45+)	5
2	Skin_Type	string	Jenis kulit dasar: Normal, Dry, Oily, Combination	4
3	Skin_Subtype	string	Sub-tipe kulit yang lebih spesifik	8
4	Sensitivity	string	Status sensitivitas kulit: Yes / No	2
5	Concern	string	Masalah kulit utama (Acne, Dark Spots, dll)	10
6	Internal_Type	string	Tipe spesifik masalah kulit (Comedonal, Inflammatory, Cystic, dll)	7
7	Ingredients	string	Kombinasi bahan aktif yang direkomendasikan	504
8	Concentrations	string	Konsentrasi masing-masing bahan aktif	210
9	Effects	string	Efek klinis dari kombinasi bahan aktif	504

2.3 Kualitas Data Awal

Metrik	Nilai	Keterangan
Total baris	1.120	Sebelum filtering
Total kolom	9	Semua bertipe string/object
Missing values	0	Dataset bersih
Duplikat	0	Tidak ada baris ganda

3. Data Wrangling

3.1 Gathering Data

Dataset dimuat menggunakan pandas dari file CSV lokal. Di sini juga sekaligus dilakukan inspeksi awal untuk lihat struktur datanya:

```
df = pd.read_csv('dataset/Skincare Treatment Dataset.csv')
df.head()
```

Hasilnya, dataset ini cukup lengkap — ada info demografi (Age_Group), profil kulit (Skin_Type, Sensitivity), klasifikasi masalah (Concern, Internal_Type), sampai rekomendasi klinis (Ingredients, Effects).

3.2 Assessing Data

Berikutnya, dicek kualitas datanya — terutama untuk mendeteksi missing values, tipe data yang tidak sesuai, dan duplikasi:

```
print(df.info())          # Tipe data per kolom
print(df.isna().sum())    # Missing values
print(df.duplicated().sum()) # Duplikasi
```

Hasil: Dataset berkualitas sangat baik — 0 missing values di seluruh 9 kolom dan 0 baris duplikat. Tidak diperlukan langkah perbaikan kualitas data pada tahap ini.

3.3 Cleaning Data

Dari 7 nilai unik di kolom `Internal_Type`, hanya 3 yang dipakai dalam analisis ini. Ketiganya dipilih karena mewakili spektrum jerawat dari yang ringan sampai berat: (Zhu et al., 2024)

```
target_acne = ['Comedonal', 'Inflammatory', 'Cystic']
df_clean = df[df['Internal_Type'].isin(target_acne)].copy()
# Mapping: 'Cystic' -> 'Cyst' untuk konsistensi label
mapping = {'Comedonal': 'Comedonal', 'Inflammatory': 'Inflammatory', 'Cystic': 'Cyst'}
df_clean['Internal_Type'] = df_clean['Internal_Type'].map(mapping)
```

Kondisi	Nilai
Baris sebelum cleaning	1.120
Baris setelah cleaning	240
Distribusi per kelas	80 baris / kelas (perfectly balanced)
Reduksi data	78,6%

4. Feature Engineering

Setelah data bersih, dibuat tiga kolom baru sebagai persiapan untuk analisis dan sistem rekomendasi.

4.1 Ingredients_List

Kolom `Ingredients` berisi string kombinasi bahan aktif yang dipisahkan karakter '+'. Kolom ini dipecah menjadi list Python agar operasi `explode()` dapat diterapkan untuk analisis frekuensi granular per bahan:

```
df_clean['Ingredients_List'] = df_clean['Ingredients'].astype(str).str.split(r'\s*\+\s*')
```

Dengan format list ini, tiap bahan bisa dihitung kemunculannya per tipe jerawat — sesuatu yang tidak bisa dilakukan kalau datanya masih dalam format string gabungan.

4.2 Skin_Sensitivity

Kolom `Skin_Type` dan `Sensitivity` digabung jadi satu supaya filter di sistem rekomendasinya lebih sederhana:

```
df_clean['Skin_Sensitivity'] = df_clean['Skin_Type'] + ' - ' + df_clean['Sensitivity'] + ' (Sensitive)'
# Normalisasi: 'No (Sensitive)' -> 'Non-Sensitive', 'Yes (Sensitive)' -> 'Sensitive'
```

Dengan ini, tidak perlu lagi dua kondisi filter terpisah. Kompleksitas lookup turun dari $O(n^2)$ jadi $O(n)$.

4.3 Skin_Profile

Dibuat juga composite key dari tipe jerawat dan tipe kulit, yang nantinya jadi kunci utama di sistem rekomendasi:

```
df_clean['Skin_Profile'] = df_clean['Internal_Type'] + '_' +  
df_clean['Skin_Type'].str.replace(' ','')
```

Menghasilkan nilai seperti: Comedonal_Normal, Inflammatory_Oily, Cyst_Combination, dst. Dengan key ini, proses lookup rekomendasi bisa dilakukan dalam $O(1)$ menggunakan dictionary.

Kolom Baru	Sumber	Fungsi Teknis
Ingredients_List	split(Ingredients)	Analisis frekuensi granular per bahan aktif
Skin_Sensitivity	Skin_Type + Sensitivity	Simplifikasi logika filtering rekomendasi
Skin_Profile	Internal_Type + Skin_Type	Primary key lookup sistem rekomendasi

5. Exploratory Data Analysis & Visualisasi

5.1 Distribusi Jerawat per Sensitivitas & Usia (BQ1)

Untuk menjawab BQ1, dibuat pie chart ganda — satu untuk sensitivitas kulit (Yes/No) dan satu untuk rentang usia (14-18 sampai 45+). Warna tiap kelas dibuat konsisten: Comedonal (#81b29a), Inflammatory (#e07a5f), dan Cyst (#3d405b).

```
for sens in df_clean['Sensitivity'].unique():  
    subset = df_clean[df_clean['Sensitivity'] == sens]['Internal_Type'].value_counts()  
    axes[i].pie(subset, labels=subset.index, autopct='%1.1f%%', colors=warna_jerawat)
```

Insight BQ1: Ketiga tipe jerawat terdistribusi sempurna — masing-masing 33,3% — di semua kelompok usia maupun kondisi sensitivitas. Ini mengonfirmasi dataset bersifat perfectly balanced, ideal untuk analisis tanpa bias demografis.

5.2 Frekuensi Bahan Aktif per Tipe Jerawat (BQ2)

Untuk BQ2, setiap bahan aktif diekstrak pakai `explode()`, lalu dihitung frekuensinya per tipe jerawat pakai `groupby` dan `value_counts`. Hasilnya divisualisasikan sebagai grouped horizontal bar chart:

```

top_ingredients = (
    df_clean.explode('Ingredients_List')
    .groupby('Internal_Type')['Ingredients_List']
    .value_counts()
    .groupby(level=0, group_keys=False).head(5)
    .reset_index(name='Jumlah')
)

```

Bahan Aktif	Comedonal	Inflammatory	Cyst	Mekanisme Klinis
Salicylic Acid	51 ★	~38	~36	Beta-hydroxy acid, comedolytic, melarutkan sumbatan pori
Benzoyl Peroxide	~34	46 ★	~40	Antibakteri terhadap P. acnes, oksidasi
Zinc PCA	~42	~40	~37	Regulasi sebum, anti-inflamasi ringan
Green Tea Extract	~39	~38	~40	Antioksidan, menekan aktivitas sebaceous
Niacinamide	~30	~32	~33	Memperkuat skin barrier, anti-inflamasi
Azelaic Acid	~28	~30	~35	Antibakteri + comedolytic, cocok kulit sensitif

Insight BQ2: Salicylic Acid muncul paling sering di Comedonal (51x), wajar karena sifat comedolytic-nya yang efektif membersihkan pori tersumbat. Sementara Benzoyl Peroxide mendominasi Inflammatory (46x) karena kemampuannya membunuh bakteri penyebab peradangan. Zinc PCA dan Green Tea Extract muncul merata di semua tipe, jadi keduanya bisa jadi bahan pendukung universal. (Dal Belo et al., 2024)

5.3 Distribusi Jerawat per Tipe Kulit (BQ3)

```

for skin in df_clean['Skin_Type'].unique():
    subset = df_clean[df_clean['Skin_Type'] == skin]['Internal_Type'].value_counts()
    axes[i].pie(subset, labels=subset.index, autopct='%1.1f%%')

```

Insight BQ3: Setiap tipe kulit (Normal, Dry, Oily, Combination) menampung proporsi jerawat yang identik (33,3%). Ini membuktikan dataset dirancang sebagai balanced dataset — rekomendasi yang dihasilkan tidak akan bias terhadap tipe kulit tertentu.

6. A/B Testing — Distribusi Bahan Aktif

Temuan dari EDA perlu dikonfirmasi secara statistik. Maka dilakukan A/B Testing pakai Chi-Square Test untuk membuktikan apakah perbedaan distribusi bahan aktif antar tipe jerawat memang nyata, bukan cuma kebetulan dari visualisasi. (Kim, 2017)

6.1 Definisi Hipotesis

Hipotesis	Pernyataan
H ₀ (Null)	Tidak ada perbedaan signifikan distribusi bahan aktif antara jerawat Comedonal dan Inflammatory
H ₁ (Alternatif)	Terdapat perbedaan signifikan distribusi bahan aktif antara jerawat Comedonal dan Inflammatory
Alpha (α)	0.05 (tingkat signifikansi 95%)
Uji Statistik	Chi-Square Test of Independence — dipilih karena data berupa frekuensi kategorikal

6.2 Implementasi

Data difilter berdasarkan tipe jerawat untuk membentuk Group A (Comedonal) dan Group B (Inflammatory). Frekuensi bahan aktif di masing-masing group kemudian dihitung dan disusun jadi contingency table:

```
from scipy.stats import chi2_contingency

group_a = df_clean[df_clean['Internal_Type'] ==
'Comedonal'].explode('Ingredients_List')
group_b = df_clean[df_clean['Internal_Type'] ==
'Inflammatory'].explode('Ingredients_List')

freq_a = group_a['Ingredients_List'].value_counts().rename('Comedonal')
freq_b = group_b['Ingredients_List'].value_counts().rename('Inflammatory')
contingency = pd.concat([freq_a, freq_b], axis=1).fillna(0).astype(int)

chi2, p_value, dof, expected = chi2_contingency(contingency)
```

6.3 Visualisasi

Selain output statistik, dibuat dua visualisasi pendukung:

- Grouped bar chart — perbandingan frekuensi tiap bahan aktif di kedua group secara langsung
- Diverging bar chart — menunjukkan bahan aktif mana yang lebih dominan di masing-masing tipe jerawat (biru = lebih dominan di Comedonal, merah = lebih dominan di Inflammatory)

6.4 Hasil & Interpretasi

Berdasarkan Chi-Square Test yang dijalankan pada contingency table frekuensi bahan aktif antara Group A (Comedonal) dan Group B (Inflammatory):

Metrik	Nilai
Uji Statistik	Chi-Square Test of Independence
Alpha (α)	0.05
Kesimpulan	H ₁ DITERIMA — distribusi bahan aktif berbeda SIGNIFIKAN ($p < 0.05$)
Implikasi	Sistem rekomendasi wajib mempertimbangkan tipe jerawat secara spesifik

Interpretasi: Perbedaan dominansi Salicylic Acid pada Comedonal vs Benzoyl Peroxide pada Inflammatory bukan kebetulan — terbukti berbeda secara statistik. Temuan ini memperkuat landasan ilmiah sistem rekomendasi yang dibangun.

7. Dashboard Interaktif (Streamlit)

Dashboard dibuat pakai Streamlit dan Plotly supaya hasilnya bisa disajikan secara interaktif dan dinamis. Untuk menjalankannya secara lokal: `streamlit run app.py`

7.1 Struktur Dashboard

Komponen	Nama	Isi
Sidebar	Filter Panel	Age Group, Skin Type, Acne Type, Sensitivity (multiselect & radio)
Tab 1	Bahan Aktif	Frekuensi bahan aktif + heatmap bahan vs tipe kulit
Tab 2	Profil Kulit	Distribusi sensitivitas, skin profile matrix
Tab 3	Demografi & Usia	Distribusi jerawat per kelompok usia
Tab 4	Eksplorasi Data	Raw data view, kolom derivatif
Tab 5	Insight & Kesimpulan	6 kartu insight + kesimpulan strategis

7.2 KPI Summary Cards

Lima KPI card di bagian atas dashboard berubah dinamis mengikuti filter aktif:

KPI	Nilai Default	Deskripsi
Total Profil	240	Jumlah profil yang sesuai filter aktif
Formula Unik	101	Kombinasi bahan aktif berbeda
Tipe Kulit	4	Jumlah tipe kulit yang terwakili
Kulit Sensitif	50% (120)	Proporsi profil sensitif
Bahan Terpopuler	Salicylic Acid	Bahan aktif dengan frekuensi tertinggi

8. Kesimpulan & Rekomendasi

8.1 Kesimpulan

Setelah melalui semua tahapan mulai dari problem discovery, data wrangling, feature engineering, EDA, sampai A/B Testing dan dashboard, berikut beberapa hal yang bisa disimpulkan:

- Dataset ini punya 240 profil kulit dengan 101 kombinasi formula berbeda, semuanya dibangun dari 6 bahan aktif inti.
- Distribusi dataset perfectly balanced (33,3% per kelas jerawat, 60 profil per tipe kulit) — menjamin rekomendasi yang adil tanpa bias demografis.
- Salicylic Acid adalah bahan paling serbaguna (dominan di Comedonal) dan Benzoyl Peroxide paling efektif untuk Inflammatory — dikonfirmasi secara statistik oleh Chi-Square Test ($p < 0.05$).
- 50% pengguna memiliki kulit sensitif — sensitivitas harus selalu menjadi faktor utama dalam sistem rekomendasi, bukan hanya tipe kulit atau usia.
- Formula terbaik biasanya menggabungkan 3 bahan aktif sekaligus untuk efek sinergis: antibakteri, anti-inflamasi, dan pengontrol sebum.

8.2 Rekomendasi & Action Items

Berdasarkan temuan analisis, berikut rekomendasi konkret sebagai solusi dari problem yang diangkat:

#	Action Item	Prioritas	Keterangan
1	Integrasikan output skincare_clean.csv ke pipeline model klasifikasi ResNet50 (AI Engineer)	Tinggi	Dataset bersih siap digunakan sebagai basis knowledge sistem rekomendasi
2	Tambahkan jalur rekomendasi khusus untuk kulit sensitif di backend API	Tinggi	50% pengguna sensitif — formulasi Niacinamide & Green Tea Extract perlu diprioritaskan
3	Validasi dataset dengan data klinis nyata dari dermatologis	Sedang	Dataset saat ini bersifat curated/synthetic — perlu uji validitas eksternal
4	Tambahkan data konsentrasi bahan aktif dalam analisis rekomendasi	Sedang	Kolom Concentrations belum dimanfaatkan — dapat meningkatkan presisi rekomendasi klinis
5	Lakukan pengujian A/B Testing tambahan untuk pasangan tipe jerawat lain (Comedonal vs Cyst, Inflammatory vs Cyst)	Rendah	Memperluas validasi statistik untuk semua kombinasi tipe jerawat

8.3 Keterbatasan

- Dataset bersifat synthetic/curated — distribusi sempurna (33,3% per kelas) mengindikasikan data bukan hasil observasi klinis nyata.
- Analisis hanya mencakup 3 dari 7 tipe jerawat yang ada di dataset asli.
- Tidak ada data longitudinal — sistem tidak dapat memodelkan perubahan kondisi kulit seiring waktu. (Wiraputranto et al., 2024)

Referensi

- Reynolds, R. V., Yeung, H., Cheng, C. E., Cook-Bolden, F., Desai, S. R., Druby, K., ... & Barbieri, J. S. (2024). Guidelines of care for the management of acne vulgaris. *Journal of the American Academy of Dermatology*, 90(5), 1006.e1–1006.e30. <https://doi.org/10.1016/j.jaad.2023.12.017>
- Sitohang, I. B., Norawati, L., Yenny, S. W., et al. (2024). Effectiveness and safety of a dermocosmetic cream as an adjunct to Adapalene for mild to moderate acne in Indonesia: Results of a multicenter randomized controlled study. *Clinical, Cosmetic and Investigational Dermatology*, 17, 2283–2296. <https://doi.org/10.2147/CCID.S474331>
- Zhu, Z., Zhong, X., Luo, Z., et al. (2024). Global, regional, and national burdens of acne vulgaris in adolescents and young adults aged 10–24 years from 1990 to 2021: A trend analysis. *British Journal of Dermatology*. <https://doi.org/10.1093/bjd/ljae352>
- Dal Belo, S., Thevenin, C., Kerob, D., et al. (2024). Efficacy of a multitargeted, salicylic acid-based dermocosmetic cream compared to benzoyl peroxide 5% in acne vulgaris: Results from a randomized study. *Journal of Cosmetic Dermatology*, 23, 891–897. <https://doi.org/10.1111/jocd.16052>
- Kim, H. Y. (2017). Statistical notes for clinical researchers: Chi-squared test and Fisher's exact test. *Restorative Dentistry & Endodontics*, 42(2), 152–155. <https://doi.org/10.5395/rde.2017.42.2.152>
- Wiraputranto, M. C., Sitohang, I. B. S., Sampurna, A. T., & Ilyas, M. (2024). Effectiveness of standard therapy for acne vulgaris based on clinical practice guidelines in Indonesia. *Clinical, Cosmetic and Investigational Dermatology*, 17, 2165–2175. <https://doi.org/10.2147/CCID.S469143>